Aprendizaje por refuerzo

Bandits

Antonio Manjavacas Lucas

manjavacas@ugr.es

Índice

Motivación

- Ya conocemos las diferencias entre aprendizaje instructivo y evaluativo.

Motivación

- Ya conocemos las diferencias entre aprendizaje instructivo y evaluativo.
- También hemos visto que el aprendizaje evaluativo es la base del aprendizaje por refuerzo.

Motivación

- Ya conocemos las diferencias entre aprendizaje instructivo y evaluativo.
- También hemos visto que el aprendizaje evaluativo es la base del aprendizaje por refuerzo.

OBJETIVO: profundizar sobre el *aprendizaje evaluativo* en un entorno simplificado, en el cual no es necesario aprender a actuar en más de una situación.

- Es una simplificación de los problemas de *reinforcement learning* completos.
- Esto nos permitirá introducir algunos conceptos básicos.

Bandits

Entornos no asociativos

- Los problemas de RL pueden entenderse como problemas de toma de decisiones.
  - Un agente recibe información del entorno y **decide** qué acción realizar.
- En un problema de RL **completo**, consideramos múltiples estados, así como diferentes acciones a realizar dependiendo de qué estado perciba el agente.
  - Las acciones pueden afectar el estado del entorno y, por tanto, influir en las recompensas futuras.
- Antes de abordar problemas de RL complejos, estudiaremos un problema simplificado donde el concepto de *estado* no es tan relevante, y únicamente se tienen en cuenta las *acciones* a realizar por el agente.
  - Es lo que llamos un entorno no asociativo.

Bandits

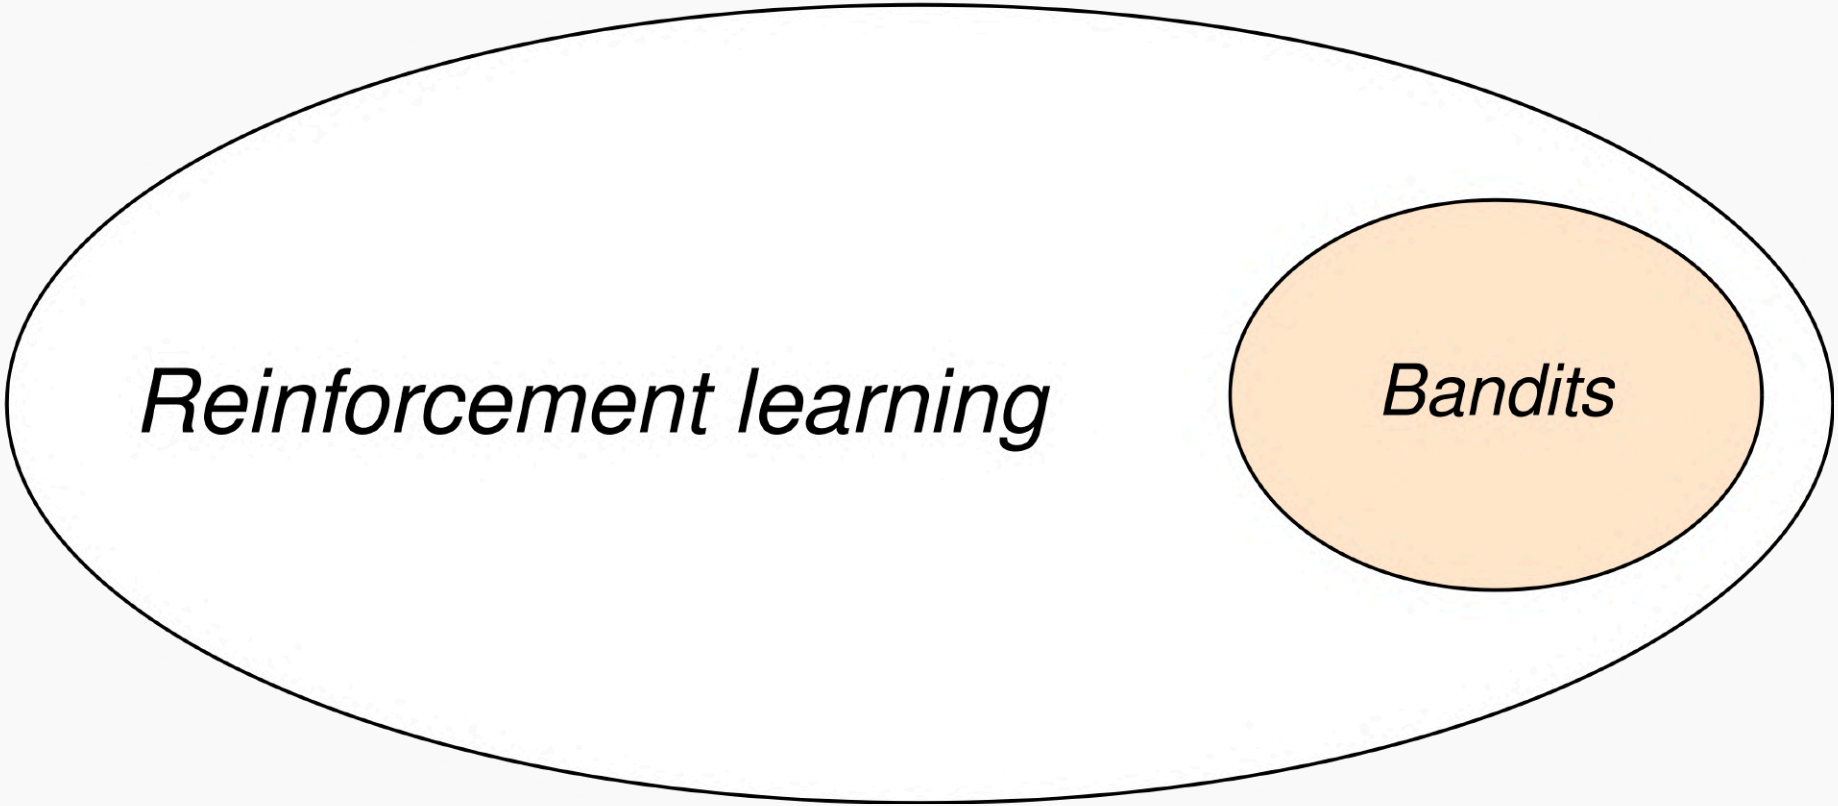

El problema de los *K-armed bandits*

- ***K-armed bandits***, también llamado *multi-armed bandit problem* o "problema de las *tragaperras multi-brazo*" (🙃).
- Problema clásico en RL y teoría de la probabilidad.
- Extrapolable a campos tan variados como ensayos clínicos, gestión empresarial, economía, *marketing*...
- Existen muchas variantes, pero nos centraremos en la versión más básica del problema.

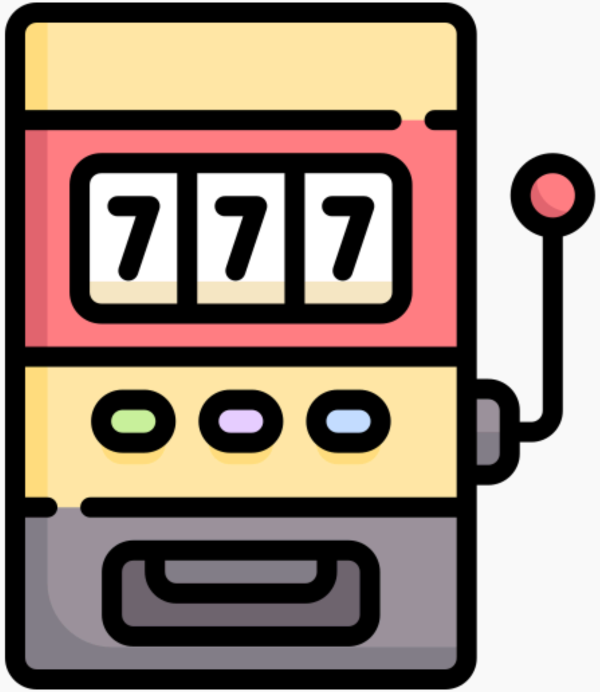

Armed bandit

El problema de los *K-armed bandits*

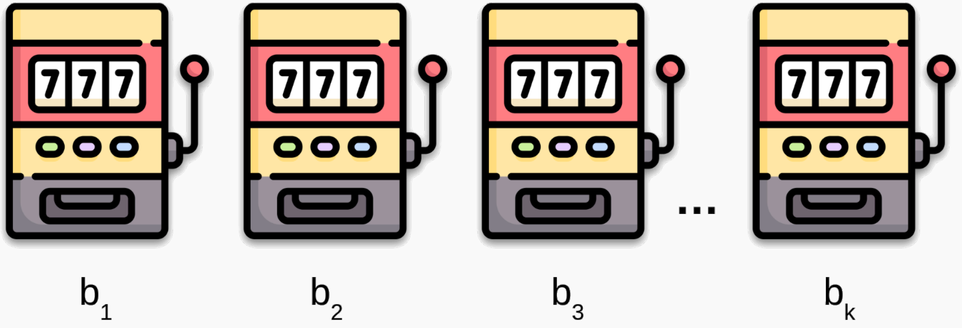

K-armed bandits

Tenemos un número arbitrario (K) de máquinas tragaperras.

- En cada instante de tiempo t, accionamos una máquina y recibimos una recompensa (💸).
- Cada máquina puede comportarse de forma diferente.
- Desconocemos la **distribución de recompensas** de cada máquina.

OBJETIVO: obtener la mayor cantidad de dinero posible (**recompensa acumulada**).

El problema de los *K-armed bandits*

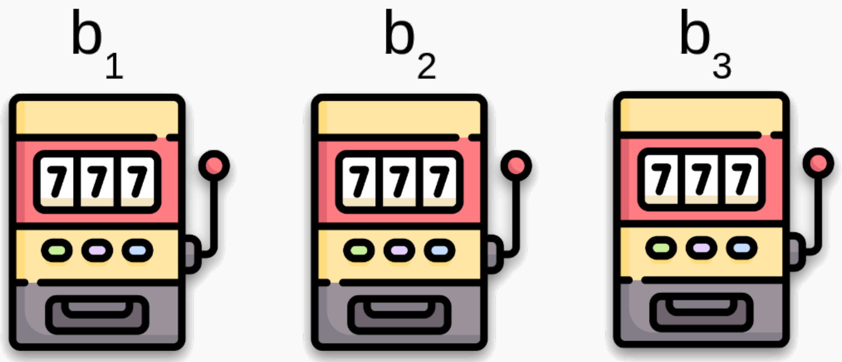

3-armed bandits

$$b_1 : \mu = 10, \sigma = 2$$

$$b_2 : \mu = 10, \sigma = 4$$

$$b_3 : \mu = 7, \sigma = 2$$

Distribuciones de recompensas: medias y desviaciones típicas

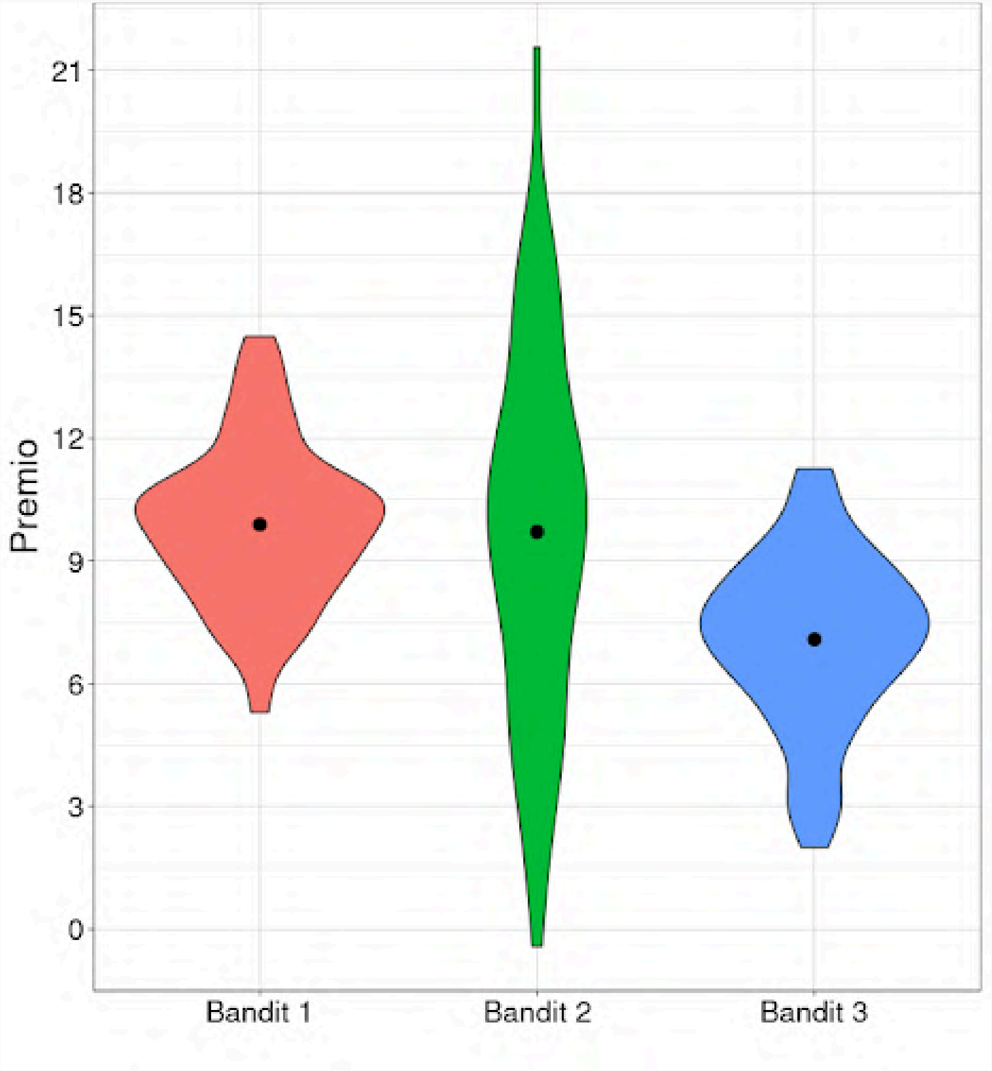

El problema de los *K-armed bandits*

Buscamos maximizar la recompensa acumulada concentrando nuestras acciones en las mejores acciones.

- Las recompensas medias de b_1 y b_2 son similares. No obstante, b_2 es más conservador (menor $\sigma \rightarrow$ valores más próximos a la media).
- Jugar b_2 es más arriesgado (mayor σ), porque puede darnos mejores recompensas que b_2 y b_3, pero también recompensas mucho peores.
- Jugar b_3 no parece una buena idea...

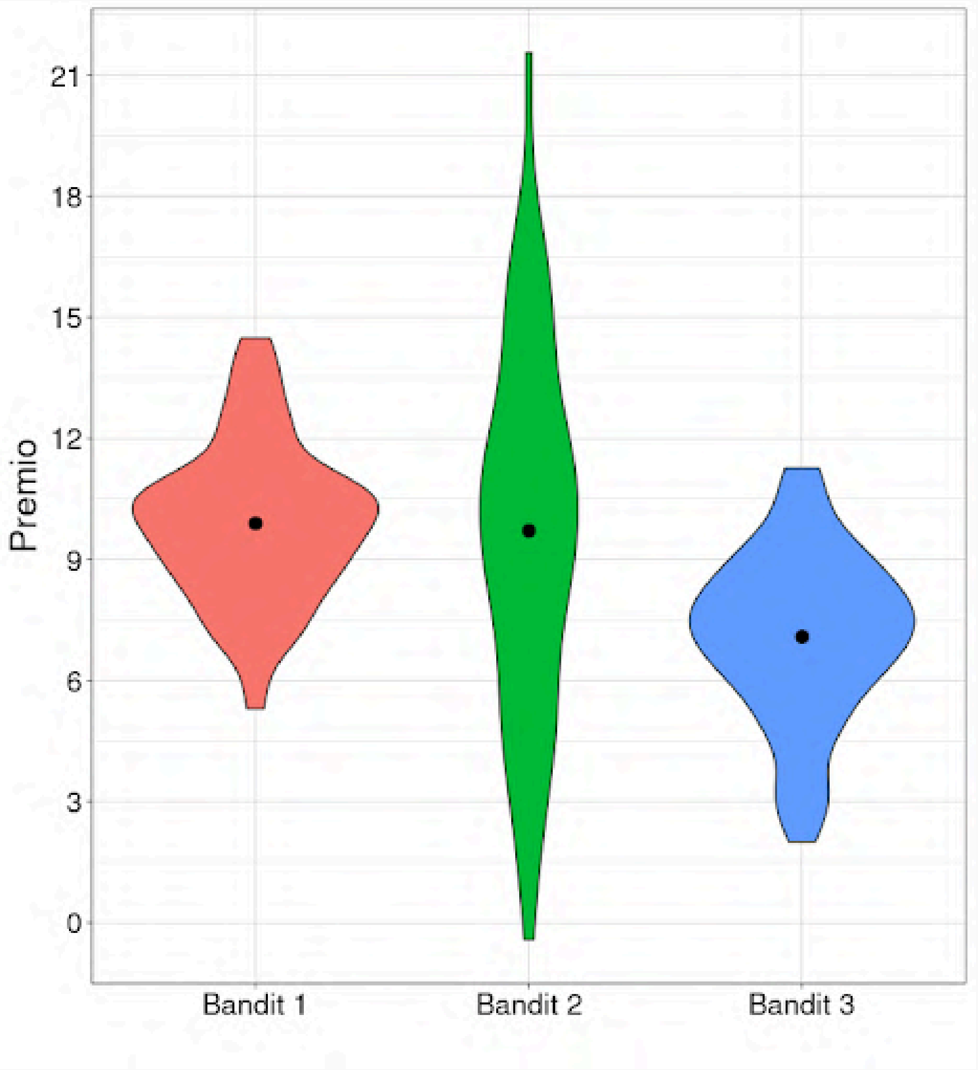

El problema de los *K-armed bandits*

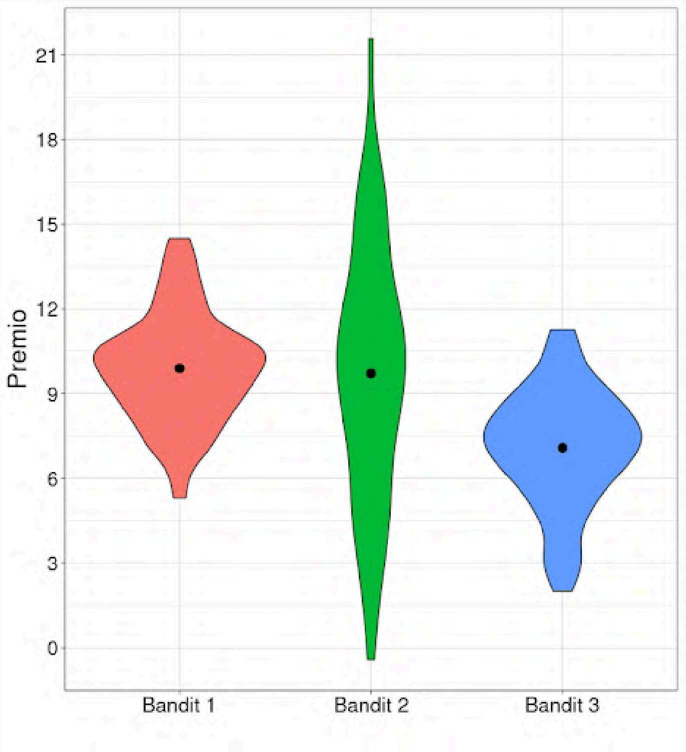

Espacio de acciones:

$$\mathcal{A} = \{a_1, a_2, a_3\}$$

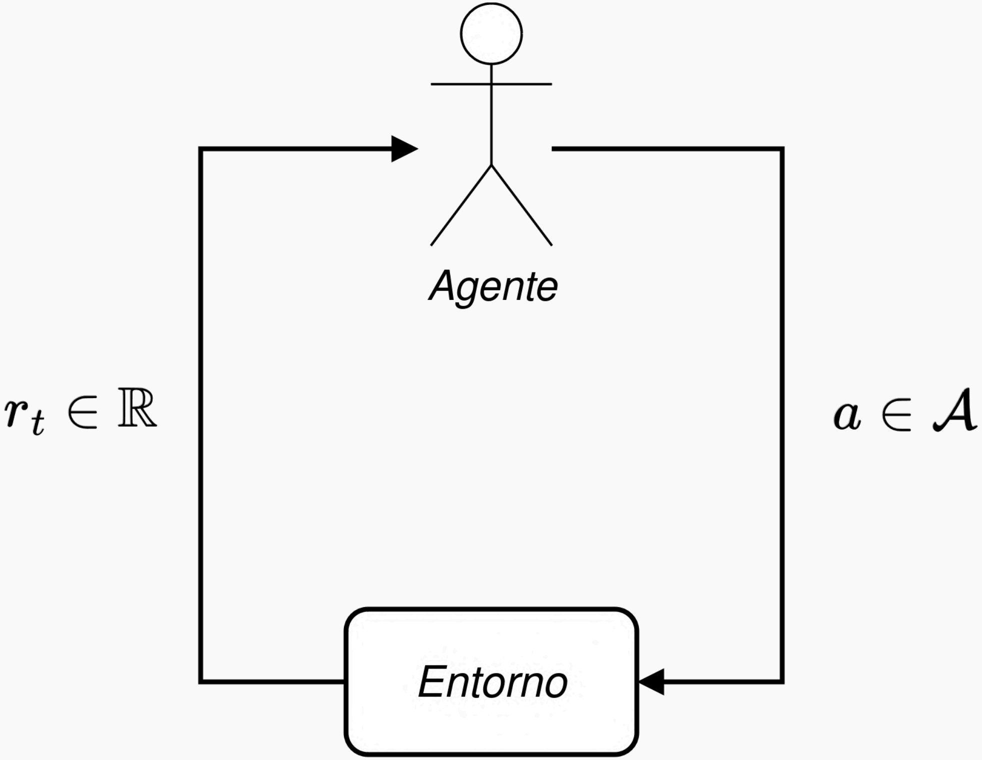

El problema de los *K-armed bandits*

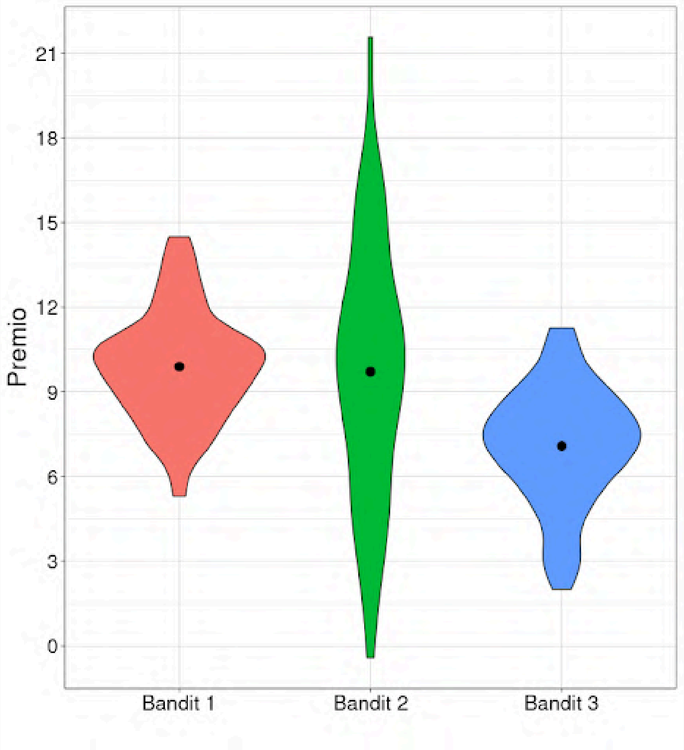

Espacio de acciones:

$$\mathcal{A} = \{a_1, a_2, a_3\}$$

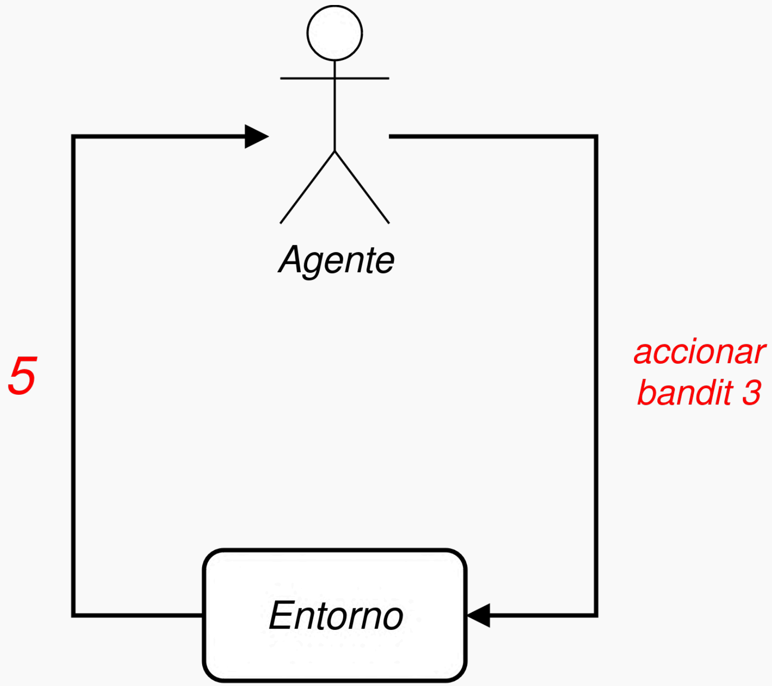

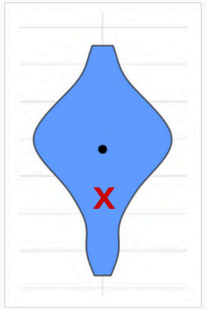

Valor de una acción

El **valor de una acción** (*action-value*) es la recompensa que esperamos obtener al realizarla:

$$q_*(a) = \mathbb{E}\left[R_t \mid A_t = a\right]$$

Valor de una acción

El **valor de una acción** (*action-value*) es la recompensa que esperamos obtener al realizarla:

$$\underbrace{q_*(a)}_{\substack{\text{Valor de} \\ \text{la acción}}} = \underbrace{\mathbb{E}\left[R_t \mid A_t = a\right]}_{\substack{\text{Recompensa esperada} \\ \text{al realizar dicha acción}}}$$

$\mathbb{E}$ representa el **valor esperado:**

$$\mathbb{E}(x) = \sum x \, P(X = x)$$

- Suma ponderada de los posibles valores de x por sus probabilidades.
- Relevante en problemas estocásticos donde R_t viene dada por una distribución de probabilidad.

Problemas deteministas y estocásticos

Problema determinista

Toda acción $a \in \mathcal{A}$ siempre tiene las mismas consecuencias.

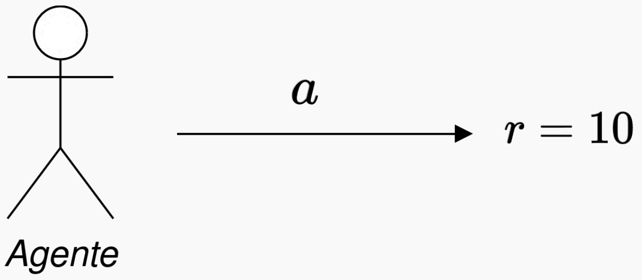

Problema estocástico

Realizar una acción $a \in \mathcal{A}$ puede conducirnos a diferentes recompensas o estados a partir de situaciones similares.

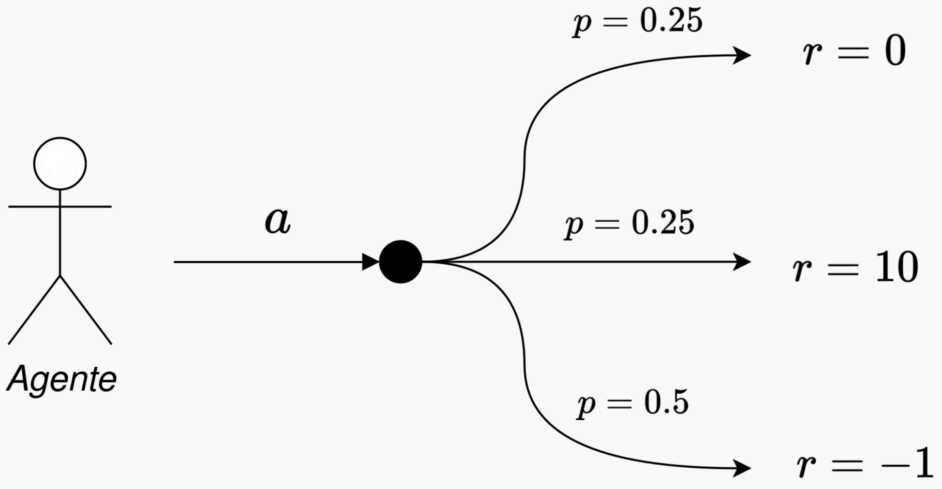

Valor de una acción

Si desarrollamos la fórmula:

$$q_*(a) = \mathbb{E}\left[R_t \mid A_t = a\right] = \sum_r r\, p(r|a)$$

Valor de una acción

Si desarrollamos la fórmula:

$$q_*(a) = \mathbb{E}\left[R_t \mid A_t = a\right] = \underbrace{\textstyle\sum_r r\, p(r|a)}_{\text{Suma ponderada de las recompensas por sus probabilidades}}$$

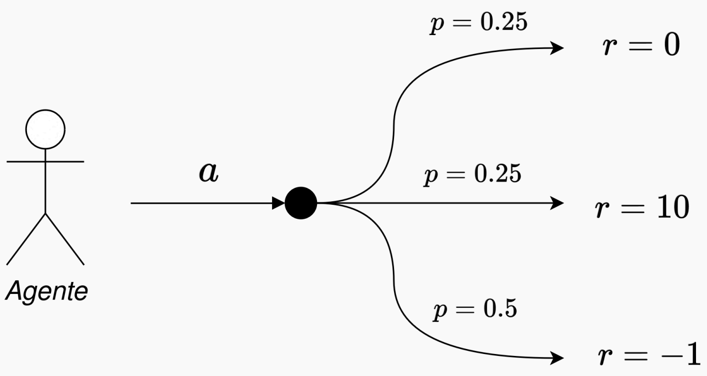

$$q_*(a) = 0 \cdot 0.25 + 10 \cdot 0.25 + \cdot (-1) \cdot 0.5$$
$$= 0 + 2.5 - 0.5 = \mathbf{2}$$

Valor de una acción

Como, a priori, no conocemos los valores reales de cada acción, consideramos valores estimados:

$$Q_t(a) \approx q_*(a)$$

Estos valores se irán aproximando a los reales a medida que ampliemos nuestra **experiencia**.

Pero...

¿Cómo aproximamos progresivamente los valores de las acciones?

Exploración *vs.* explotación

Exploración *vs.* explotación

Consideremos el siguiente caso:

- Tenemos 3 bandits y, por tanto, 3 posibles acciones.
- Inicialmente, desconocemos el valor de cada acción: $q_*(a) = 0, \forall a \in \mathcal{A}$.
- Por tanto, comenzamos eligiendo una acción arbitraria. Es decir, exploramos.

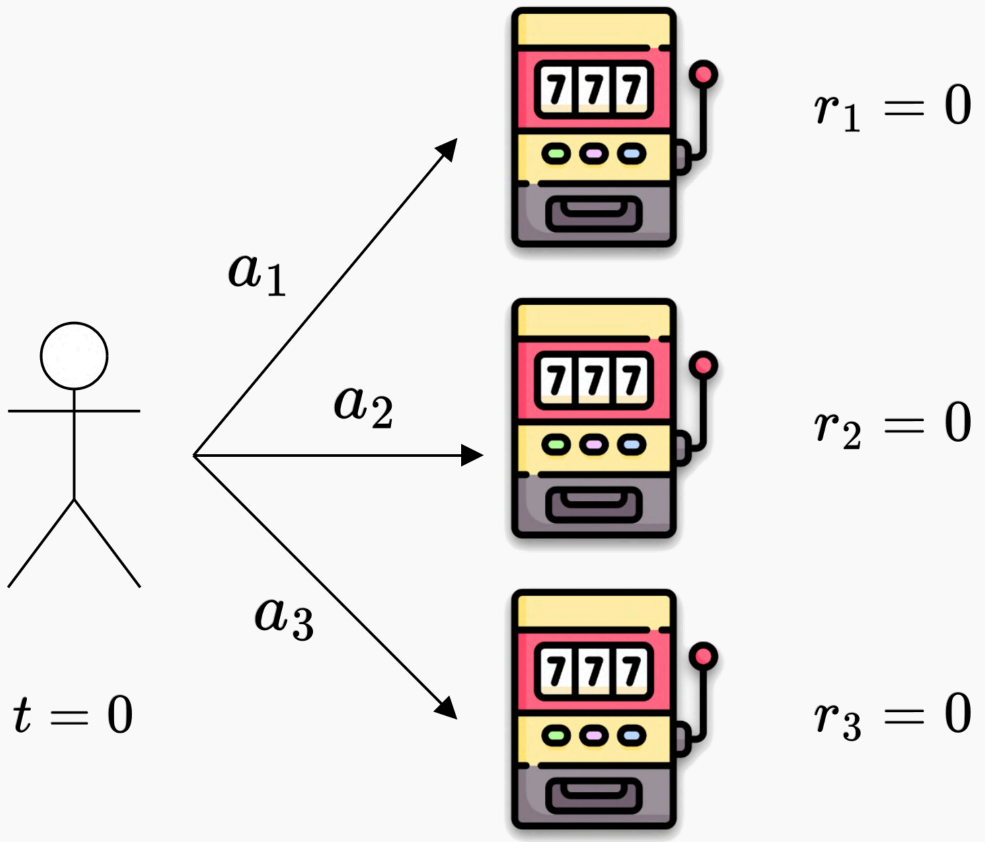

Exploración *vs.* explotación

- El agente elige a_1 y recibe una recompensa $r_1 = 1$.
- Posteriormente, convendrá explorar a_2 y a_3 para comprobar si son mejores opciones.

Explorar implica sacrificar recompensas inmediatas conocidas para probar alternativas hasta el momento no contempladas.

Esta inversión podría llevarnos a obtener mayores recompensas *a largo plazo*.

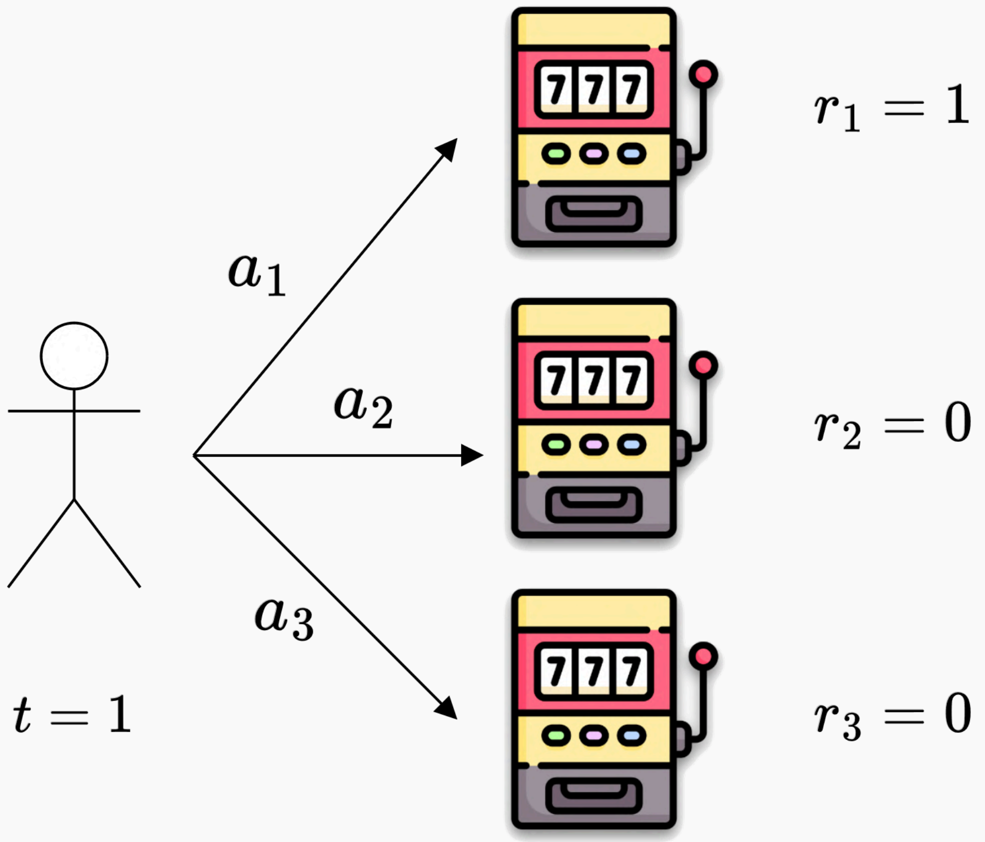

Exploración *vs.* explotación

- Es una idea similar a elegir entre un **restaurante** de confianza o uno que no has visitado nunca... 🍴
- ...o entre tu género de **películas** favorito y otro que no sueles ver... 🎥
- ...o entre un **producto** que sueles comprar y otro que podría interesarte... 🛒

¿Intuyes las posibles aplicaciones?

Exploración *vs.* explotación

- Es una idea similar a elegir entre un **restaurante** de confianza o uno que no has visitado nunca... 🍴
- ...o entre tu género de **películas** favorito y otro que no sueles ver... 🎥
- ...o entre un **producto** que sueles comprar y otro que podría interesarte... 🛒

¿Intuyes las posibles aplicaciones?

Exploración *vs.* explotación

- El agente elige a_2 y recibe una recompensa $r_2 = 10$.

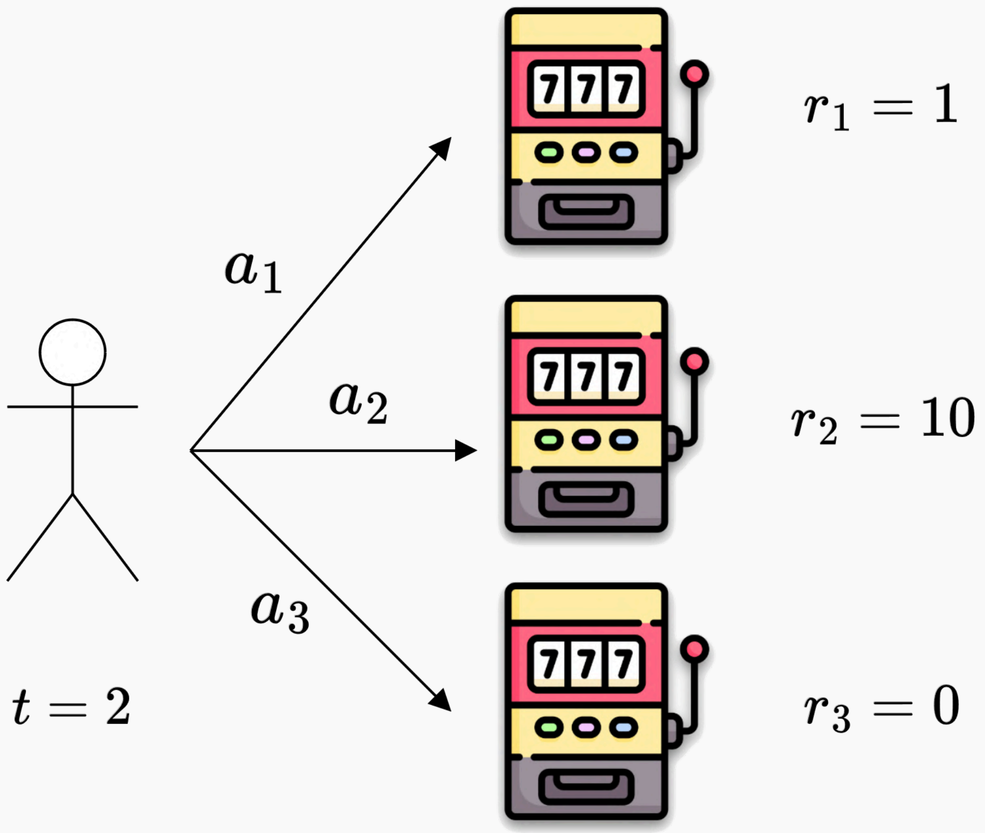

Exploración *vs.* explotación

- El agente elige a_3 y recibe una recompensa $r_3 = 5$.

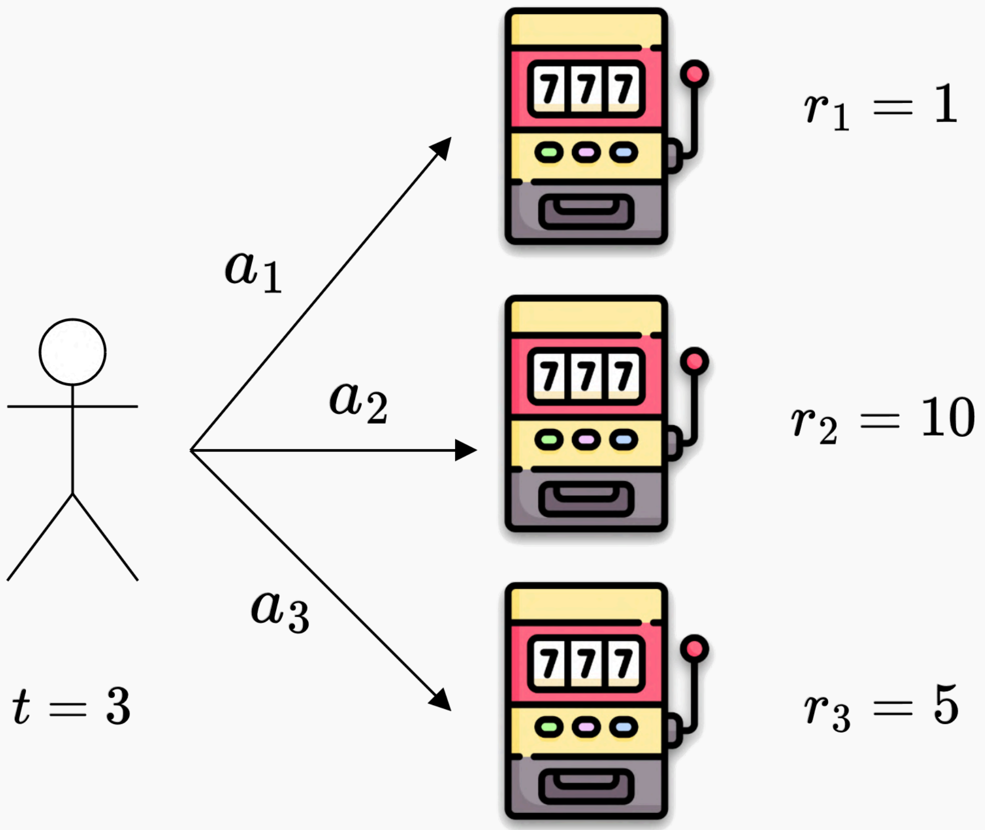

Exploración *vs.* explotación

En $t = 3$ hemos realizado todas las acciones posibles y recibidas sus correspondientes recompensas.

A partir de aquí podemos:

a) Actuar de forma ***greedy*** (“voraz”), **explotando** indefinidamente la mejor acción (a_2).

b) Mantener un comportamiento aleatorio, **explorando** continuamente las distribuciones de recompensa asociadas a cada acción.

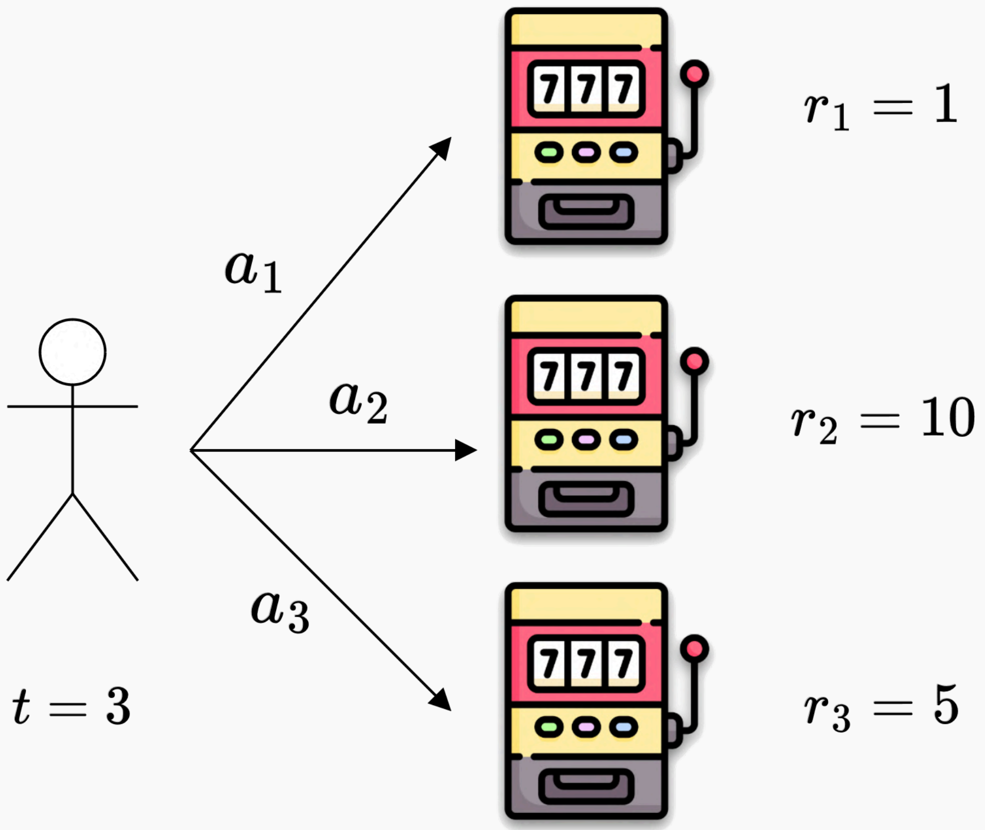

Exploración *vs.* explotación

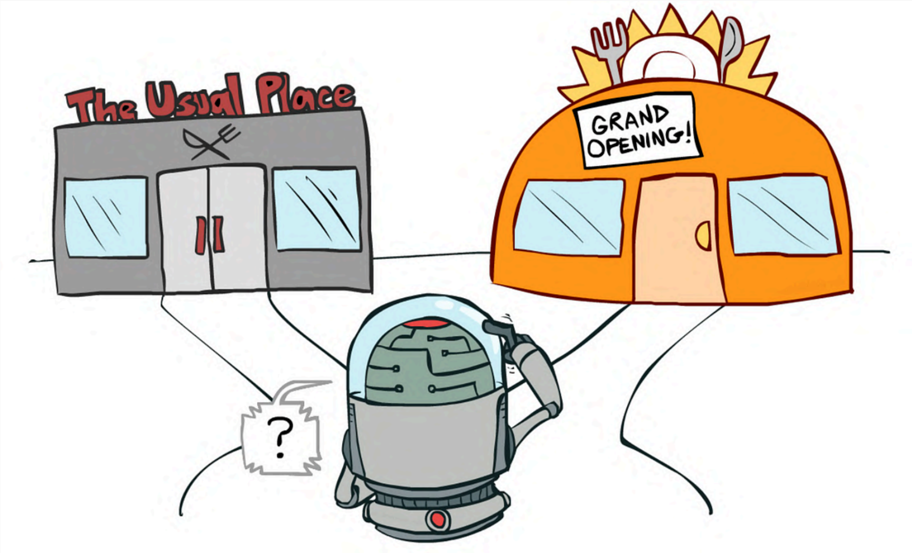

No es posible **explorar** y **explotar** a la vez, lo que conduce a un **conflicto**.

- *Exploration-exploitation trade-off*

Elegir una estrategia u otra dependerá de diferentes factores: incertidumbre, estimaciones, tiempo restante...

Trataremos de buscar un **balance** entre exploración y explotación, siguiendo un comportamiento **ε-greedy**.

ε-greedy

La estrategia ε-greedy consiste en:

- **Explotar** (ser *greedy* con respecto a la mejor acción) con probabilidad **$1 - \varepsilon$**.
- **Explorar** (elegir una acción aleatoria) con probabilidad **ε**.

ε-greedy

- Para poder actuar de forma *greedy* necesitamos saber qué acción es la mejor.
- Pero una acción puede no darnos siempre la misma recompensa...

¿Cómo determinamos el valor de una acción?

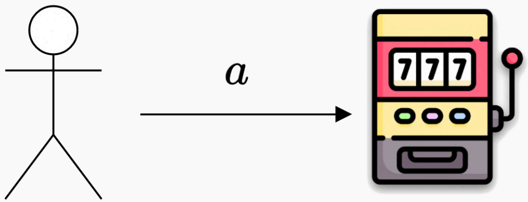

$$
\left\{
\begin{array}{l}
r_0 = 1 \\
r_1 = 0 \\
r_2 = 7 \\
r_3 = 1 \\
r_4 = 3 \\
\quad \dots
\end{array}
\right.
$$

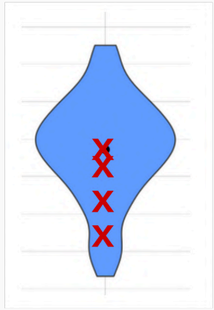

Estimación de *action–values*

Estimación de *action–values*

Existen diferentes formas de estimar el valor de una acción.

Un método a considerar es la media muestral (*sample-average method*):

$$Q_t(a) = \frac{\sum_{i=1}^{t-1} R_{i,a}}{\sum_{i=1}^{t-1} n_{i,a}}$$

$$t \to \infty, \quad Q_t(a) = q_*(a)$$

- El valor estimado de una acción es la suma de las recompensas ofrecidas hasta el momento entre el número de veces que se ha elegido.
- Si t tiende a ∞, el valor estimado $Q_t(a)$ convergerá en el valor real $q_*(a)$.

Acciones *greedy*

¿Cómo emplear el valor estimado para elegir una acción?

Selección de acciones *greedy*:

$$A_t = \text{argmax}_a \, Q_t(a)$$

- Seleccionar la acción con el mayor valor estimado.
- Si varias acciones tienen el mismo valor, podemos fijar un criterio (ej. selección aleatoria, la primera, etc.).

Acciones ε-*greedy*

¿Cómo emplear el valor estimado para elegir una acción?

ε-greedy combina la estrategia *greedy* con la probabilidad ε de explorar:

$$A_t = \begin{cases} \text{argmax}_a\, Q_t(a) & \text{con prob. } 1-\varepsilon \\ a \sim \text{Uniform}(\{a_1, a_2, \ldots a_k\}) & \text{con prob. } \varepsilon \end{cases}$$

- Cuanto menor sea ε, más tardaremos en converger en los valores reales.
- Es posible ir reduciendo ε con el paso del tiempo (a medida que los valores convergen).

Ejemplo

Consideremos el espacio de acciones: $\mathcal{A} = \{a_1, a_2\}$

¿Cuál es la probabilidad de elegir a_2 siguiendo una estrategia ε-*greedy* con $\varepsilon = 0.5$?

Ejemplo

Consideremos el espacio de acciones: $\mathcal{A} = \{a_1, a_2\}$

¿Cuál es la probabilidad de elegir a_2 siguiendo una estrategia ε-*greedy* con $\varepsilon = 0.5$?

$$P(a_2) = 0.5 \cdot 0.5 = \mathbf{0.25}$$

Ejemplo

Consideremos el espacio de acciones: $\mathcal{A} = \{a_1, a_2\}$

¿Cuál es la probabilidad de elegir a_2 siguiendo una estrategia ε-*greedy* con $\varepsilon = 0.5$?

$$P(a_2) = \underbrace{0.5}_{\text{Probabilidad de explorar}} \cdot \underbrace{0.5}_{\text{Probabilidad de que la acción elegida sea } a_2} = 0.25$$

¿Qué método elegir?

Podemos asumir que la elección de un método u otro se realizará cuando todas las acciones hayan sido probadas, al menos, una vez.

- Si las recompensas son valores únicos ($\sigma = 0$), elegiremos siempre la acción con mejores resultados.
  - En este caso, ***greedy*** es mejor.

¿Qué método elegir?

Podemos asumir que la elección de un método u otro se realizará cuando todas las acciones hayan sido probadas, al menos, una vez.

- Si las recompensas son valores únicos ($\sigma = 0$), elegiremos siempre la acción con mejores resultados.
  - En este caso, ***greedy*** es mejor.
- Si las recompensas se corresponden con una distribución de probabilidad ($\sigma > 0$), nos interesa no perder la posibilidad de explorar.
  - Por tanto, es mejor ***ε-greedy***.
  - Especialmente en problemas con *noisier rewards* → mayor varianza de las distribuciones.

No estacionareidad

Problema no estacionario

Decimos que un problema de decisión es no estacionario si las distribuciones de recompensa varían con el tiempo.

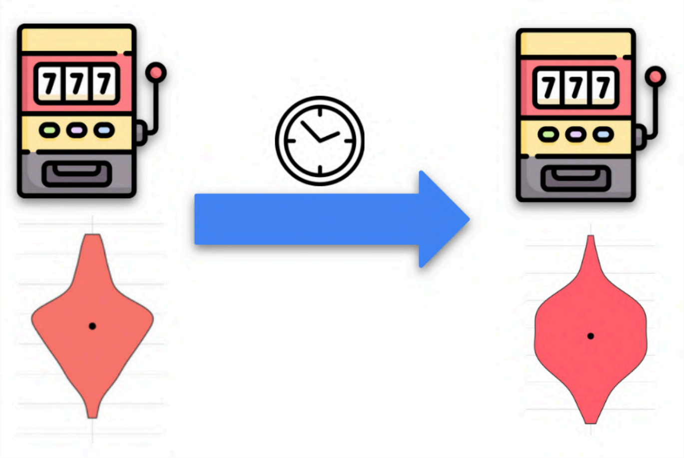

- Una acción, *a priori*, mala puede mejorar con el tiempo, y viceversa.
- Es un fenómeno muy común en aprendizaje por refuerzo.

En este tipo de problemas, la mejor estrategia es ε-*greedy*, porque nunca se descarta la posibilidad de explorar y, por tanto, de reaprender las distribuciones de recompensa.

Cálculo incremental de *action-values*

Valor estimado de una acción

Previamente hemos propuesto estimar el valor de las acciones de la siguiente forma:

$$Q_t(a) = \frac{\sum_{i=1}^{t-1} R_{i,a}}{\sum_{i=1}^{t-1} n_{i,a}}$$

El problema de este cálculo es que requiere mantener en **memoria** todas las recompensas obtenidas para cada acción en el tiempo.

- En problemas con un gran espacio de acciones, o prolongados en el tiempo, este método es inviable en términos de escalabilidad.

SOLUCIÓN: cálculo incremental de la media.

Cálculo incremental del *action-value*

Si desarrollamos la fórmula para el cálculo del *action-value* medio, podemos conseguir que este cálculo sea **incremental**.

No depende de todas las recompensas anteriores, sino únicamente del ***action-value* actual** y de la **última recompensa** obtenida.

$$
\begin{aligned}
Q_{n+1} &= \frac{1}{n}\sum_{i=1}^{n} R_i \\
&= \frac{1}{n}\left(R_n + \sum_{i=1}^{n-1} R_i\right) \\
&= \frac{1}{n}\left(R_n + (n-1)\frac{1}{n-1}\sum_{i=1}^{n-1} R_i\right) \\
&= \frac{1}{n}\left(R_n + (n-1)Q_n\right) \\
&= \frac{1}{n}\left(R_n + nQ_n - Q_n\right) \\
&= Q_n + \frac{1}{n}\left(R_n - Q_n\right)
\end{aligned}
$$

Cálculo incremental del *action-value*

$$Q_{n+1} = \frac{1}{n}\sum_{i=1}^{n} R_i = Q_n + \frac{1}{n}\left(R_n - Q_n\right)$$

Se trata de una regla de actualización incremental (*incremental update rule*) bastante frecuente en RL:

$$\text{nuevoValor} \leftarrow \text{valorActual} + \text{stepSize}(\text{objetivo} - \text{valorActual})$$

O bien:

$$v_t \leftarrow v_t + \alpha\left[G_t - v_t\right],\ \alpha \in (0, 1]$$

Cálculo incremental del *action-value*

$$Q(A) \leftarrow Q(A) + \underbrace{\frac{1}{N(A)}}_{\text{step size}} \cdot \underbrace{\left[\underbrace{R}_{\text{objetivo}} - \underbrace{Q(A)}_{\text{estimación actual}} \right]}_{\text{error de estimación}}$$

- El error de estimación se reduce a medida que las estimaciones se acercan al objetivo.
- Indica la diferencia entre la recompensa obtenida y el valor actual.
  - Determina cuánto nos hemos equivocado en nuestra estimación más reciente.

Cálculo incremental del *action-value*

$$Q(A) \leftarrow Q(A) + \underbrace{\frac{1}{N(A)}}_{\substack{\text{step}\\\text{size}}} \cdot \underbrace{\left[\underbrace{R}_{\text{objetivo}} - \underbrace{Q(A)}_{\substack{\text{estimación}\\\text{actual}}} \right]}_{\text{error de estimación}}$$

- El *step-size* pondera la importancia que damos al error de estimación.
  - Determina el peso de la nueva información recibida.
- Lo que hacemos es añadir un pequeño ajuste al valor anterior de la acción, que depende de la diferencia entre la recompensa obtenida y nuestra estimación anterior del valor de la acción.

Ejemplo: piedra, papel, tijeras

R = +1 si se gana   R = 0 si se pierde o empata $\alpha = \frac{1}{N}$

t	Yo	Rival	Recompensa	Actualización	Q(tijeras)
0	-	-	-	-	0
1	✂️	🪨	0	$Q(\text{tijeras}) = 0 + 1(0 - 0)$	0
2	✂️	📄	+1	$Q(\text{tijeras}) = 0 + \frac{1}{2}(1 - 0)$	0.1
3	✂️	🪨	0	$Q(\text{tijeras}) = 0.5 + \frac{1}{3}(0 - 0.5)$	0.09
4	✂️	✂️	0	$Q(\text{tijeras}) = 0.335 + \frac{1}{4}(0 - 0.335)$	0.081
...	...	...	...	...	...
N-1	-	-	-	-	0.33

Ejemplo: piedra, papel, tijeras

¿Y si variamos el *step size*? $\alpha = 0.1$

t	Yo	Rival	Recompensa	Actualización	Q(tijeras)
0	-	-	-	-	0
1			0	$Q(\text{tijeras}) = 0 + \mathbf{0.1}(0 - 0)$	0
2			+1	$Q(\text{tijeras}) = 0 + \mathbf{0.1}(1 - 0)$	0.5
3			0	$Q(\text{tijeras}) = 0.5 + \mathbf{0.1}(0 - 0.5)$	0.335
4			0	$Q(\text{tijeras}) = 0.335 + \mathbf{0.1}(0 - 0.335)$	0.25125
...	...	...	...	...	...
N-1	-	-	-	-	0.33

Elección del *step size*

La principal diferencia entre *step sizes* es la velocidad de convergencia:

- $\alpha = \frac{1}{N}$ supone una convergencia más lenta a medida que aumenta N. Esto provoca que actualizaciones más pequeñas y menos impactantes con el paso del tiempo.

  Deseable si queremos dar más peso a las experiencias tempranas.

- Si se utiliza un *step size* constante, $\alpha \in (0, 1]$, la estimación del *action-value* converge más rápido hacia su valor real, pero es más sensible a experiencias recientes.

  Más efectivo cuando se desea dar más peso a las experiencias recientes.

Elección del *step size*

- En problemas estacionarios, los métodos basados en media muestral (*average sampling*) son apropiados, porque las distribuciones de probabilidad de las recompensas no varían con el tiempo.
  - Es decir, preferimos $\alpha = \frac{1}{N}$
- En problemas no estacionarios, es más importante dar mayor peso a las recompensas recientes.
  - Por tanto, optamos por $\alpha \in (0, 1]$

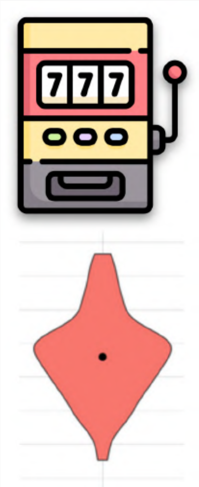

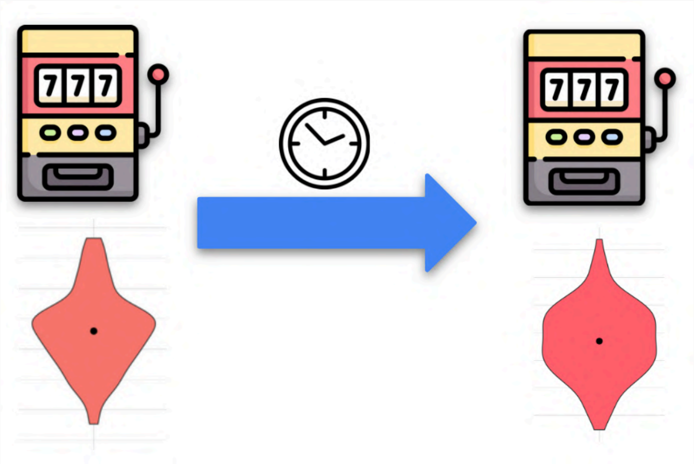

Elección del *step size*

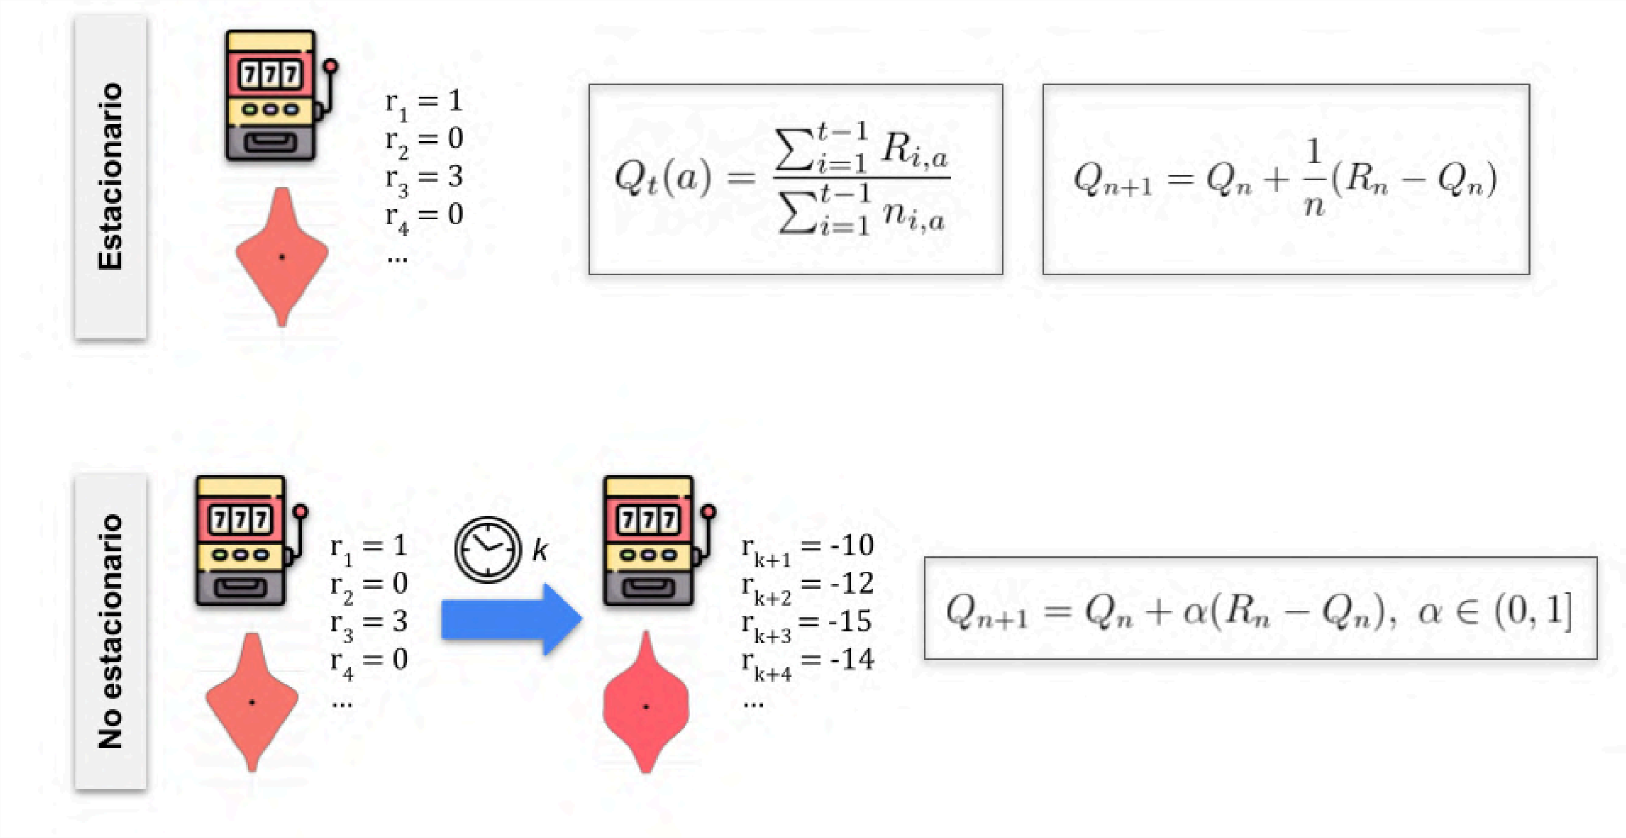

Valores iniciales

Los métodos vistos hasta el momento dependen en gran medida de las estimaciones de los *action-values* iniciales.

Esto supone un sesgo (*bias*).

- En el método de la **media muestral**, si inicialmente todas las acciones tienen valor 0, habrá un sesgo hacia la primera acción de la que se obtenga una recompensa > 0.
- **El sesgo desaparece una vez hemos seleccionado todas las acciones posibles.**

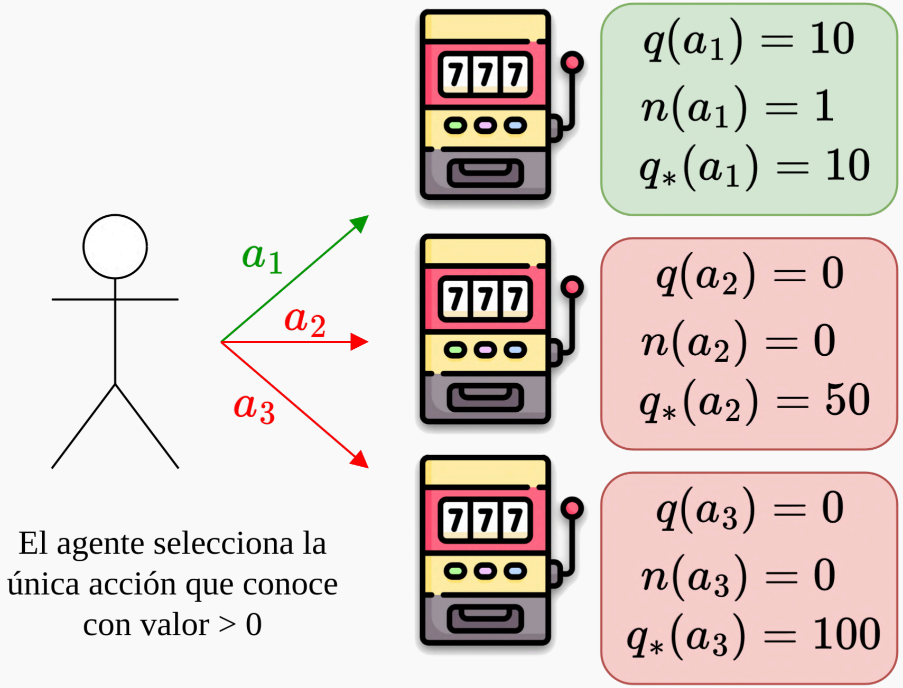

Valores iniciales optimistas

En métodos con *step size constante*, el sesgo es permanente, aunque decrece con el tiempo:

$$
\begin{aligned}
Q_{n+1} &= Q_n + \alpha\left[R_n - Q_n\right] \\
&= (1 - \alpha)^n Q_1 + \sum_{i=1}^{n} \alpha(1 - \alpha)^{n-i} R_i
\end{aligned}
$$

Valores iniciales optimistas

En métodos con *step size constante*, el sesgo es permanente, aunque decrece con el tiempo:

$$Q_{n+1} = Q_n + \alpha\left[R_n - Q_n\right]$$
$$= (1-\alpha)^n Q_1 + \underbrace{\sum_{i=1}^{n} \alpha(1-\alpha)^{n-i} R_i}_{\text{A mayor número de experiencias pasadas (n) menor peso tienen las recompensas anteriores}}$$

Valores iniciales optimistas

En la práctica, el sesgo no suele ser un problema y a veces puede resultar muy útil.

- Las estimaciones inciales pueden proporcionar conocimiento previo/experto sobre qué recompensas podemos esperar de cada acción.
- Un inconveniente es que estas estimaciones iniciales se convierten en un conjunto de parámetros que el usuario debe elegir, aunque por defecto pueden ser = 0.

Sesgo como apoyo a la exploración

Podemos utilizar el sesgo para guitar la exploración inicial de nuestro agente. Por ejemplo:

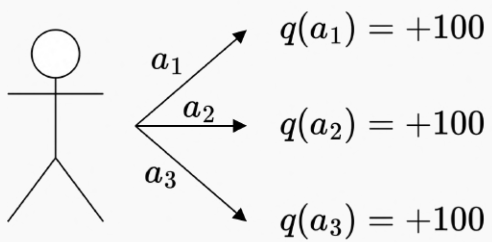

Se asignan falsos valores iniciales de +100 a cada acción, a pesar de que los valores reales estén en [−2, +2].

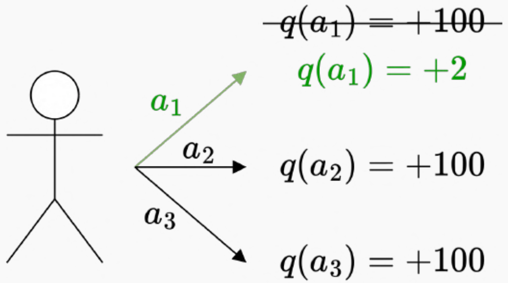

Se elige una acción en base a su valor estimado inicial. Podría ser la mejor, pero sigue siendo peor que los valores iniciales del resto de acciones.

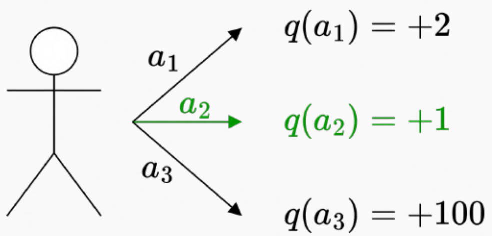

De esta forma, se aprovecha el sesgo para favorecer naturalmente la **exploración** inicial de todas las acciones posibles.

Sesgo como apoyo a la exploración

Utilizamos el sesgo para provocar la exploración inicial de todas/algunas acciones.

Esto permite que incluso un método *greedy* explore.

- Se denomina *optimistic greedy*, porque emplea valores iniciales optimistas.
  - Puede dar lugar a mejores resultados que un ε-*greedy* estándar.
- La principal limitación es que la exploración es simplemente inicial (disminuye con el tiempo hasta desaparecer).
  - Esto hace que no sea útil en problemas **no estacionarios**.

> *"The beginning of time occurs only once, and thus we should not focus on it too much".*
>
> *Sutton, R. S., & Barto, A. G. (2018). Reinforcement learning: An introduction (2nd ed.). MIT press. (p. 35).*

Upper-confidence-bound

Exploración ε-*greedy*

ε-*greedy* fuerza la seleccion de acciones *non-greedy* de forma indiscriminada:

$$A_t = \begin{cases} \text{argmax}_a\, Q_t(a) & \text{con prob. } 1-\varepsilon \\ a \sim \text{Uniform}(\{a_1, a_2, \ldots a_k\}) & \text{con prob. } \varepsilon \end{cases}$$

- Todas tienen la misma probabilidad.
- No hay preferencia por aquellas más cercanas al valor *greedy*, o aquellas menos visitadas/desconocidas.

Sería interesante explorar acciones ***non-greedy*** de acuerdo a su **potencial** para ser óptimas.

Para decidir qué acción explorar, podemos considerar:

A) La cercanía al valor máximo actual
- El valor de la acción *greedy*

B) La incertidumbre en las estimaciones.
- Qué acciones se han realizado menos (n_i)

A)

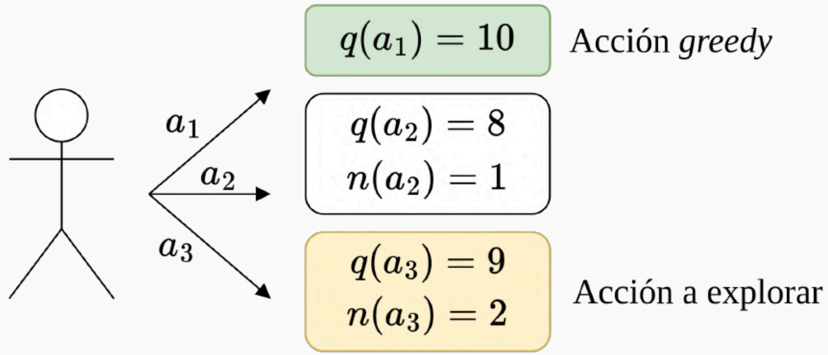

B)

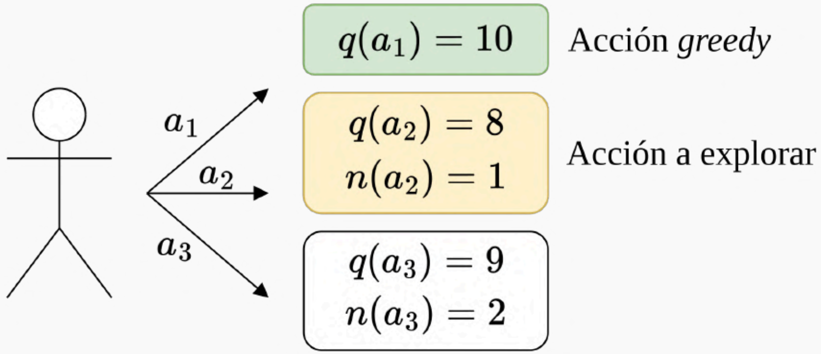

Si los combinamos...

Upper-confidence-bound

La técnica del límite superior de confianza, o *Upper-confidence-bound* (**UCB**), nos permite balancear **valor** e **incertidumbre** a la hora de seleccionar acciones:

$$A_t = \operatorname{argmax}_a \left[Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

Upper-confidence-bound

La técnica del límite superior de confianza, o *Upper-confidence-bound* (**UCB**), nos permite balancear **valor** e **incertidumbre** a la hora de seleccionar acciones:

$$A_t = \text{argmax}_a \left[Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

- $c > 0$ controla cuánto explorar.
- $N_t(a)$ indica el número de seleccione sprevias de la acción a.
  - Si $N_t(a) = 0$, se considera a como la acción más preferible

Upper-confidence-bound

$$A_t = \text{argmax}_a \left[\underbrace{Q_t(a)}_{\substack{\text{valor}\\\text{estimado}}} + \underbrace{c\sqrt{\frac{\ln t}{N_t(a)}}}_{\text{incertidumbre}} \right]$$

La selección de una acción depende de:

1. Su valor estimado hasta el momento.
2. La incertidumbre sobre dicha acción.
    - Cada vez que una acción se selecciona, su incertidumbre se reduce.
    - Según pasa el tiempo, la incertidumbre sobre una acción vuelve a aumentar poco a poco.

El coeficiente c pondera la importancia que damos a la exploración.

UCB reduce la exploración con el tiempo (el término de incertidumbre tiende a 0).

Incertidumbre en las estimaciones

Definimos intervalos de confianza dentro de los cuales se encuentran los valores originales de las acciones y, por tanto, sus estimaciones:

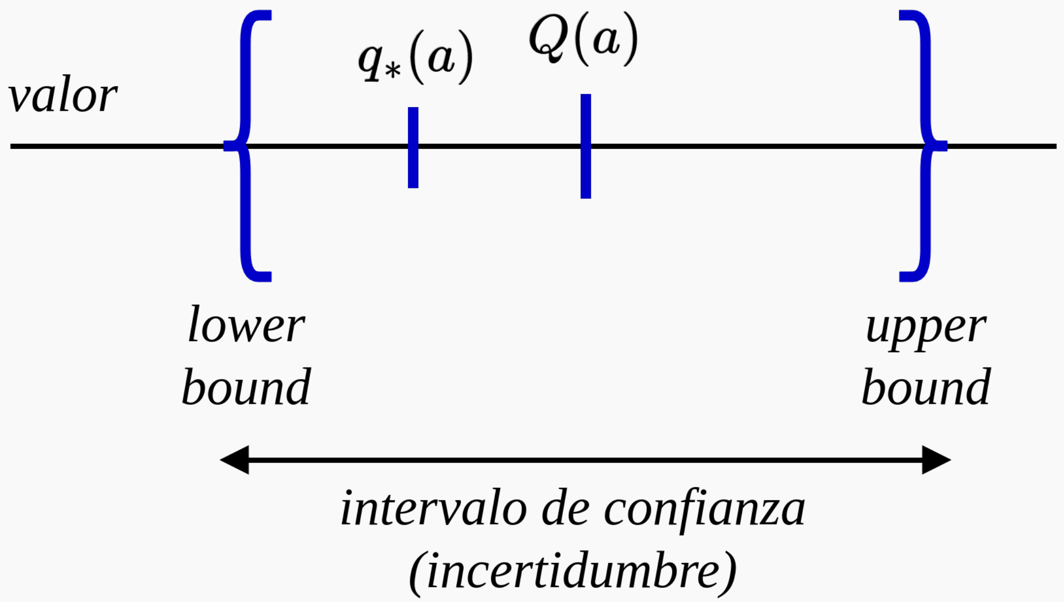

Incertidumbre en las estimaciones

Opción 1. Elegir la acción con mayor incertidumbre (**exploración**).

- A mayor incertidumbre, mayor creencia de que es bueno (*optimismo en presencia de incertidumbre*).
- Elegimos la acción a_1 en base a $c\sqrt{\frac{\ln t}{N_t(a)}}$.

Opción 2. Elegir la acción con mayor valor estimado (**explotación**).

- Elegimos la acción a_2 en base a $Q_t(a)$.

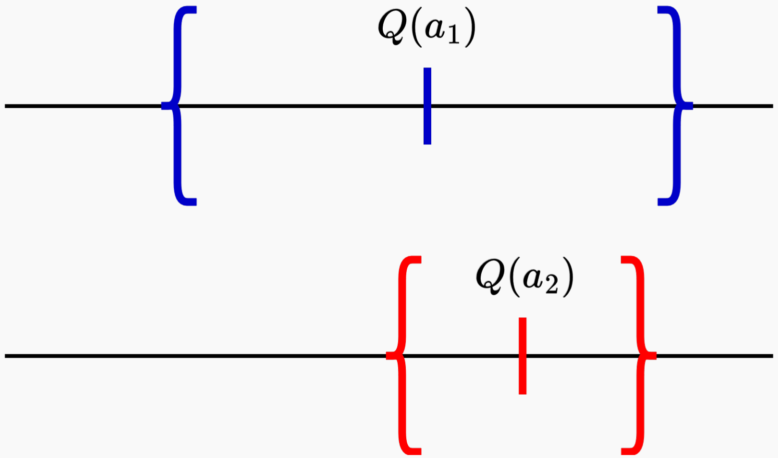

Trabajo propuesto

Trabajo propuesto

- **Implementación** y **comparativa** de los métodos *greedy*, ε-*greedy* y UCB para un ejemplo con K-armed bandits.
- ***Thompson sampling***
  - Definición y características.
  - Diferencias y similitudes con los métodos vistos.
- ***Contextual bandits***
  - ¿Qué son?
  - ¿Que relación podrían tener con las próximas lecciones?

Recursos interesantes

- https://www.ma.imperial.ac.uk/~cpikebur/trybandits/trybandits.html
- https://rlplaygrounds.com/reinforcement/learning/Bandits.html
- https://youtu.be/bkw6hWvh_3k

Aprendizaje por refuerzo

Bandits

Antonio Manjavacas Lucas

manjavacas@ugr.es